

Malicious traffic detection method based on improved sparse autoencode

Cybersecurity

Student: Xinrui Wu

Adviser: Junjiang He

Abstract: Malicious traffic detection is an important tool for protecting computer networks from threats and malicious attacks. Although many malicious traffic detection techniques have been proposed nowadays, with the development of networks, the massive high-dimensional data and the continuous emergence of new threats have made traditional detection methods that rely on prior knowledge ineffective in the face of zero-day attacks. At the same time, they cannot maintain high real-time performance when dealing with massive high-dimensional data. To address these issues, this thesis proposes a malicious traffic detection method based on an improved sparse autoencoder. This method mainly makes improvements in feature selection and model training. During feature extraction, a feature evaluation coefficient is introduced to assist in feature selection, obtaining more valuable features. During training, a joint optimization strategy is adopted to optimize the weights of the encoder and the detector with the same objective, forcing the sparse representation extracted by the autoencoder to more effectively support subsequent detection tasks. To evaluate the effectiveness of the improvement, comparative experiments were conducted on the public dataset UNSW-NB15. The experimental results show that the accuracy of this method is 90.27%, which is 0.97% and 8.97% higher than that of the improved LSTM network intrusion detection model and the standard multi-layer perceptron model MLP, respectively.

Key Words: sparse autoencoder; malicious traffic detection; feature selection; cyber-security

目 录

1 绪论	1
1.1 研究背景	1
1.2 相关工作	2
1.2.1 网络流量表示与学习	2
1.2.2 网络流量检测方法	5
1.3 论文主要工作	7
1.4 论文组织与结构	8
2 相关理论与技术	9
2.1 恶意流量检测技术	9
2.1.1 基于特征表达的检测技术	9
2.1.2 相关评估指标	10
2.2 自编码器技术	11
2.3 本章小结	12
3 技术路线	13
3.1 流量预处理	14
3.2 特征提取	15
3.1.1 特征评价系数	15
3.1.2 特征选择策略	17
3.3 模型训练	19
3.3.1 预训练	19
3.3.2 联合优化	19
3.4 检测	21
3.5 本章小结	21
4 实验	22
4.1 实验环境	22
4.2 实验结果和分析	22
4.2.1 实验数据集	22
4.2.2 验证k-稀疏自编码器改进的有效性	23
4.2.3 验证联合训练策略的有效性	24
4.2.4 与现有方法对比	25
5 总结与展望	27

5.1 论文主要工作与贡献	27
5.2 现存问题与今后工作	27
参考文献	29
声 明	32
学位论文使用授权书	32
四川大学本科毕业论文 AI 工具使用声明	33
致 谢	35

1 绪论

1.1 研究背景

在数字化转型浪潮的推动下，互联网已深度融入现代社会的各个领域，为人们提供多样且便捷的服务，成为现代社会中不可或缺的一部分。根据国际电信联盟（ITU）2024 年数据显示，全球互联网用户突破 55 亿人次，比 2023 年修订之后的估算人数增加 2.27 亿^[1]。这种指数级增长在促进数字经济繁荣的同时，也为网络安全带来严峻挑战。根据北京瑞星公司发布的《2024 年中国网络安全报告》^[2]显示，虽然 2024 年瑞星“星核”平台截获的病毒、恶意网址、手机病毒样本数量均有所下降，但网络攻击呈现多样化、复杂化的特点，预计 2025 年攻击者会更积极利用新漏洞甚至 0day 漏洞，这要求网络流量的检测系统具备较强的泛化能力，以便有效识别新出现的攻击类型。

网络流量是传输数据的关键载体，支持正常用户在使用各种应用时实现不同设备间的通信，然而，网络攻击也隐藏在每天数以万计的流量中，恶意流量检测即是在合法、透明的框架下访问网络流量数据，分析其中是否存在潜在的恶意信息。流量数据包中蕴含的协议特征（如 TCP 三次握手模式）、行为特征（如访问频率）和内容特征（如 payload 结构）构成了网络空间安全态势感知的基础，通过对其分析和检测，可以及时发现网络问题，减少潜在风险。但网络流量数据通常包含大量特征，随着互联网的快速发展呈指数级增长，网络攻击手段也不断演进，海量数据处理、高维特征解析以及高实时性要求成为恶意流量检测领域面临的挑战。

传统的恶意流量检测方法多采用基于特征库匹配的检测机制，这种依赖先验知识的技术在面对未知的攻击或变种病毒时难以进行有效识别，比如 Christodorescu 等^[3]利用指令信息检测恶意程序，Bruschi 等^[4]提出了一种基于将程序 P 的控制流图与已知恶意软件的控制流图集进行比较来检测程序 P 内部的变形恶意代码的策略。随着网络发展，传统检测方法对零日攻击的检测效果不佳^{[5][6]}，且难以实时处理大规模数据，鉴于此，近年来深入分析网络流量数据并提取流量特征成为许多学者的研究方向，尝试使用机器学习和深度学习模型，分析流量特征向量进行恶意流量的检测，最终实现对已知攻击和零日攻击的有效识别，比如 Ye 等^[7]提出了一种由一个多层受限玻尔兹曼机堆叠的自编码器和一层联想存储器组成的深度学习框架，自编码器负责构建特征向量，然后用于检测新的未知恶意软件，Naeem 等^[8]构建图像特征，结合 CNN 和 DNN 识别各种离散大小图像特征中的可疑操作来对恶意软件进行分类。

机器学习和深度学习检测模型能达到的检测效果在于特征向量的构建质量，从特征维度上来说，海量高维特征向量可能出现“维度灾难”的问题，使计算复杂度增加，过拟合问题加剧，影响模型的检测效率和准确率，而特征维度太低可能无法充分捕捉数据的复杂性，丢失重要特征值，使模型准确率降低。所以，对原始流量数据进行降维的同时关注特

征的选择才能获得优质的训练数据，优质的训练数据是提高恶意流量检测效果和性能的基础。

在此背景下，自编码器^[9]（Autoencoder）因其强大的非线性表征能力受到广泛关注。与传统 PCA 等线性降维方法不同，自编码器通过编码器-解码器架构可已学习流量的深层潜在表示。 k -稀疏自编码（ k -sparse autoencoder, KSAE）^[10]引入稀疏限制，通过仅保留隐藏层的 k 个最大激活值，剩余神经元置为 0 的方式实现了特征的选择，在去除多余的信息，使流量数据的表示更加简洁和高效的同时，限制激活神经元的数量也提高了计算的效率。但本文研究发现，对流量数据而言，大多数隐藏层神经元输出的激活值都集中在 0.5 附近，在这样的情况下，特征激活值差异较小，直接选择激活值 k 个最大神经元的策略并不合适，可能面临信息损失的风险，导致检测准确率下降。

针对上述问题，本文研究提出一种改进的 k -稀疏自编码，引入了基于信息论的特征评价系数，并结合注意力机制^[11]将这一评价系数应用于激活值的选择，提高隐藏层对特征重要性的鉴别能力，保留区分性强的特征的同时去除冗余特征，为后续的检测模型提供更良好的流量特征稀疏表达。同时，受到文章^[12]的启发，采用端到端的策略，在改进的 k -稀疏自编码预训练后，将编码器的权重矩阵（负责特征提取）和分类器的权重矩阵（负责分类决策）进行联合优化，迫使稀疏表达特征空间朝着最大化分类性能的方向调整，提升模型检测的准确率。

1.2 相关工作

在恶意流量检测中，网络流量的学习、表示和检测是恶意流量检测方法的核心环节，也是提升检测准确率的关键。因此，国内外大量的研究围绕这三个方面进行，以寻求更优的方案。

1.2.1 网络流量表示与学习

特征的质量是检测模型效果的基础，结合目标任务和检测模型特点，对原始网络流量数据进行特征的选择或结构化表示可以提高数据质量，提升检测模型效果。原始网络流量数据被转换成的形式就是网络流量表示，流量表示学习技术指将原始网络流量转换为网络流量表示的手段。

（一）网络流量表示

随着研究和技术发展，从传统方法到机器学习方法，恶意流量检测技术已取得显著进展，但仍面临着一系列挑战，其中最核心的问题在于模型的性能十分依赖训练数据的规模和质量。通过网络流量数据的表示进行特征增强是解决这一问题的常用手段，然而，流量数据具有复杂性和动态性，网络流量向特征表示的映射过程中会不可避免地造成信息损失，所以，构建鲁棒的流量特征表示，增强其泛化能力以提升检测性能，已成为该领域的一个研究重点。




图 1.1 流量表示粒度与流量表示形式

如图 1.1 所示，流量数据是一种连续性数据，通常对原始流量包 pcap 文件进行流切分，提取三种不同粒度级别的离散流量数据：包级（Packet-level）、流级（Flow-level）和会话级（Session-level），再对其进行流量特征表示。

包级别流量分析主要关注数据包 (packet) 的特征及其到达过程，数据包大小分布、数据包到达时间间隔的分布等，能够非常准确地捕捉网络流量的所有细节，有效识别一些特定的攻击行为。贾等^[13]将应用层数据包解析过程分为五步，结合工控过程与协议特点，实现工控协议深度包解析，完成了对工控协议的分类。对于一些关联度高的复杂网络攻击，包级别流量分析依靠单一的数据包无法提供足够的信息来揭示整个攻击过程，存在一定局限性。

流级别流量分析聚焦于数据包之间的关联性和时间空间信息，能处理每个数据包单独来看均符合正常流量特征的要求，但数据包间的整体流量行为却隐藏恶意活动的情况。流级别数据的提取通常通过使用预定义的流量键划分数据包来实现，传统方法一般基于 N 元组（如五元组：源 IP、目的 IP、源端口、目的端口、协议）来定义流，但近年来，Gupta 等^[14]选择从特定应用程序中生成数据包子集来定义流。流级别流量分析由于其数据量和存储开销较小的特点，非常适用于快速检测和大规模流量监控。然而，因为没有深入分析数据包，会导致数据包级别的细节丢失，这将导致例如蠕虫等基于有效载荷传输的攻击难以被发现。

会话级别流量分析关注服务器与客户端之间的持续交互，通过串联数据包完整记录通信全过程，相较于流级别流量分析，会话中可能会包含一个或多个流保证会话的完整性，通过还原业务逻辑和用户意图，来捕捉隐蔽攻击，比如：陈等^[15]提出了一种隐蔽性通信行为检测方法，首先通过并行化会话流聚合算法聚合原始会话流，然后从集中趋势和离散程度的角度刻画隐蔽通信行为，引入标签传播算法扩展标签数据，最后构建多分类检测模，验证了方法对隐蔽性通信行为的检测效果。

三个不同粒度流量分析方法也可以结合使用，可以构建一个多维网络行为分析体系，包含数据包级别的细致审查、流级别的行为趋势分析以及会话级别的交互过程追踪，进而精准揭示攻击模式、深入解析攻击策略与意图。唐等^[16]提出了一种结合包检测与流检测的

SECS2 流量识别方法，能有效地识别 SECS2 数据包。

针对不同的检测方法，考虑不同检测场景的需求，流量特征的表示可以分为数值特征、可视化特征和结构化特征三类^[17]。

一般来说，通过提取流量的统计特征和时序特征将原始数据转换为数值化特征。比如：Ahmed 等^[18]通过统计分析方法计算窗口内流量特征直方图，实现正常流量特征的高效表征；Zolotukhin 等^[19]提取会话持续时间、每秒发送字节数等 8 种类统计特征用于异常检测；Teodoro 等^[20]基于数据包的到达顺序来建立时间序列模型，通过分析包间隔差异识别异常流量数据。数值化特征可以直接作为大多数机器学习模型的输入，适合快速计算，适用于实时检测场景，但简单的数值特征难以捕捉数据中的复杂非线性结构和模式。

可视化的特征表示（灰度图像，彩色图像等）可以很好地保留流量数据的时空信息，适配 CNN、Transformer 等深度学习模型，比如：Wang 等^[21]将加密流量 TCP 会话的有效载荷转换为灰度图像，从中自动提取和学习特征；周等^[22]提出一种面向多会话协同攻击场景的恶意加密流量检测方法，该方法通过提取多会话特征数据并转换为图像，利用深度学习方法在图像识别领域的优势，将加密流量识别问题转换为图像识别问题，从而间接实现了恶意加密流量检测。

结构化特征的表示方法从多方面捕获数据之间的关系和模式，通过构造结构来保留流量数据的原始结构与内在联系，然而，这种对数据完整性的维护是以高昂的计算资源消耗与存储成本为代价，在实际应用中需要平衡数据表征精度与资源开销间。比如：Mongkolluksamee 等^[23]融合基于图基的特征向量、基于传输控制协议和用户数据报协议与数据包大小相关的特征向量，构成图结构的流量表示；在加密流量方面，Shen 等^[24]提出流量交互图的概念，以数据包作为节点，以边刻画数据包间的特定关联，并融合数据包长度、数据流向、突发特性及传输顺序等要素，精准地捕捉并呈现了加密应用流量的行为特征。

（二）网络流量学习

从原始网络流量数据转换为各种特征表示依赖于特征学习方法，特征学习方法主要分别为人工特征工程和自动特征学习。

人工特征工程作为特征学习的初步阶段，其对于关键特征的选择和提取主要依赖于专家的知识 and 经验。比如：Hamamoto 等^[25]采用遗传算法（GA, genetic algorithm）自动优化特征选择，通过迭代进化找到最优的特征集合，帮助构建高性能模型；为实现分类任务特征集的优化，Maiti 等^[26]采用随机森林（RF, random forest）、决策树等算法，筛选出最具贡献度的特征；Fernandes 等^[27]借助主成分分析算法对流量数据进行特征化处理，通过降维提取流量特征并去除噪声。为学习算法设计适配的特征集，可以显著提升模型的检测准确性和泛化性能，但人工特征工程过于依赖专家知识、难以发现复杂特征组合且需要花费大量的时间和人力成本，近年来很多方法转向了自动化特征工程，尤其是利用深度学习模型自动学习特征。

利用深度学习模型的自主学习能力可以自动从原始数据中提取潜在特征，而无需人工干预。Garg 等^[28]通过改进卷积神经网络（CNN），对转换为 RGB 图像的网络流量进行关键特征抽象；Roosmalen 等^[29]借助深度神经网络和自编码器，学习数据的压缩表示并滤除噪声；Marín 等^[30]设计 Deep-MAL 框架，融合 CNN 与长短期记忆网络（LSTM）对有效载荷的固定位数字节进行自动特征提取。

综上所述，使用的流量特征学习方法，可以将网络流量表示为数值型、可视化和结构化三种类型的特征，数值型特征通过统计量化流量行为，计算效率高；可视化特征将流量映射为图，利用视觉模式增强深度学习的时空关联捕捉能力，但计算开销较大；结构化特征能保留流量内在逻辑与上下文，但建模复杂度高。流量特征表示对于流量检测特别重要，将流量数据转换为模型可处理的适当形式是提升检测性能的前提。

1.2.2 网络流量检测方法

网络流量检测方法的分类如图 1.2 所示，按照检测机制的核心原理分类，恶意流量的检测方法通常可以分为：基于异常检测，基于误用检测和混合方法。基于异常检测的核心思想是建立正常流量行为的基准模型，将偏离该模型的行为视为异常，对应“发现未知攻击”的需求，网络环境的变化（如新业务模式的出现）可能会给这种检测方法带来较高的误报率，基于此方法的检测模型训练时为了准确地捕捉到所有正常流量的特点，较依赖“纯净”的正常流量数据。基于误用检测的核心思想是利用已知攻击的特征进行匹配，直接识别恶意流量，对应“识别已知攻击”的需求，这类方法可解释性较强，在检测已知攻击时具有较高的准确率，但无法检测未知攻击且依赖高质量标注数据和特征工程。在实际场景中，通常结合基于异常检测和基于误用检测使用，即混合方法。通常，系统会先进行误用检测，快速过滤出已知的攻击，再通过异常检测进一步确认是否存在未知攻击，补充误用检测的盲区。

按照检测的技术手段分类，恶意流量的检测方法通常可以分为：传统恶意流量检测方法，机器学习和深度学习恶意流量检测方法。




图 1.2 网络流量检测方法分类

传统恶意流量检测方法主要依赖预定义规则、特征库或统计分析，何等^[31]提出了一种基于相似度的 DDoS 检测方法，该方法对高频网络流量的相邻时刻进行相似度分析，根据相似度的变化发现异常；陈等^[32]对骨干路由器的 netflow 流数据采用基于多个信息熵的联合指标，结合基于滑动窗口的熵流突发检测算法，实现了网络异常的发现。这些方法简单直观，但过于依赖先验知识且难以适应复杂多变的网络环境，这可能导致较高的误报率和漏报率。

近年来，机器学习相关技术在恶意流量检测中也得到了广泛地研究，各种分类、聚类算法均有使用。无监督技术是基于异常行为检测的关键手段，其运作逻辑在于利用历史正常流量数据构建用户行为基准模型，进而通过捕捉与该模型的明显偏差，完成对恶意流量的识别，张^[33]提出一种基于 PSO-KM 聚类分析的恶意代码检测算法，该算法既继承了 PSO 算法的全局搜索能力，又保持了 k-Means 算法的快速搜索能力，在对准确度要求较高、数据量相对较小的小型网络内的恶意代码检测上表现优异。监督学习技术是误用检测的主要手段，该检测方式通过整合正常流量与恶意流量数据，对分类器进行训练，从而实现对流量类别的直接判别，比如：Xu 等^[34]深入剖析信息熵、数据包大小、传输频率等关键特征，借助随机森林（RF, random forest）算法，构建了高效的检测模型，成功实现对加密流量中 Eclipse 攻击的精准识别。机器学习的检测方法能够自动从数据中学习规律，不依赖人工定义的规则，但大多数传统机器学习模型（如 SVM、随机森林、逻辑回归）本质上是统计学习浅层模型，复杂度有限，在处理高维复杂特征方面存在一定局限性，通常需要手动选择和提取流量特征（从原始数据中定义有意义的统计量或结构特征），将原始数据转换为适合模型处理的数据表示，算法类型选择和参数调优也需要人工干预，增加了机器学习检测方法的复杂性。

相较于机器学习,深度学习方法深层次的神经网络结构能更好地捕捉更复杂的、非线性的数据模式,且作为端到端的检测方法,能实现输入原始数据直接输出检测结果,全程自动化特征提取和检测,无需人为干预,显著降低了因多步骤处理导致的误差累积风险。Lucia 等^[35]运用一维卷积神经网络从原始字节数据中自动提取关键特征,并通过迭代学习机制精准识别恶意流量。Radford 等^[36]通过 LSTM 网络学习流序列转换的单词序列,为正常行为建模,实现对恶意行为的有效甄别。深度学习方法在特征学习和泛化能力上展现出巨大优势,但也面临着数据需求大、模型结构复杂、决策过程难以解释等挑战。

总的来看,传统方法虽然在当下较少单独使用,但统计学方法仍然可以为其它检测技术提供重要分析支撑;基于机器学习的检测方法通过训练模型进行检测,能够较准确地识别恶意流量并具有较强的自适应能力,但特征提取、模型选择和参数调整的过程较复杂;深度学习检测技术与机器学习相比有更强大的非线性模式表征能力,尤其适用于处理大规模高维网络流量数据,虽然其对训练数据和计算资源要求较高,同时存在模型解释性较差的难题,但也成为当前研究的前沿热点。

1.3 论文主要工作

研究主要包括改进 k -稀疏自编码器、联合优化编码器和恶意流量检测器和实验证明有效性并与相关方法对比三部分。

(1) 改进 k -稀疏自编码器

传统的 k -稀疏自编码器使用线性激活函数,选取激活值最大的神经元保留,虽然达到了关注稀疏性的目的,但在稀疏表达的有效性上仍有进步空间。针对以上不足,本文提出特征重要性评价系数算法与特征相关性评价系数算法,分别量化特征的判别能力与关联关系,并在此基础上设计双维度特征选择算法,通过重要性-相关性联合评估机制筛选关键特征,最终对 k -稀疏自编码器隐藏层进行改进,通过自注意力机制将上述方法运用到在隐含层神经元的选择上,以得到更有价值的稀疏表达。

(2) 联合优化编码器和恶意流量检测器

构建二分类的恶意流量检测器,为优化稀疏特征空间的判别性,提出一种改进的 k -稀疏自编码器与检测器联合优化框架,首先对改进的 k -稀疏自编码器进行单独的预训练,加速收敛,然后对编码器权重矩阵和检测器权重矩阵进行有监督的联合优化,避免传统两阶段方法的特征-任务割裂问题。

(3) 实验证明有效性并与相关方法对比

为证明改进的 k -稀疏自编码器相比传统 KSAE,能生成更具判别性的稀疏特征,设计实验一:分别使用传统 k -稀疏自编码器和改进 k -稀疏自编码器对流量数据进行稀疏表达,再用这些稀疏表达作为训练数据分别训练恶意流量检测器,比较检测器的各个指标,证明改进的有效性。

为验证联合优化框架(编码器与分类器端到端训练)相比两阶段方法(先特征提取后

独立训练分类器) 的优势, 设计实验二: 对比使用传统两阶段方法和联合优化方法的检测器各个指标, 证明联合优化的有效性。

为证明本文方法在公开数据集 UNSW-NB15 上优于现有方法, 设计实验三: 对比本文方法和基于改进 LSTM (Long Short-Term Memory, LSTM) 入侵检测算法模型、标准多层感知器模型 MLP (Multilayer Perceptro, MLP) 在 UNSW-NB15 数据集上的准确率和误报率, 证明本文方法的优越性。

1.4 论文组织与结构

本文研究内容共分为五个章节。第一章和第二章阐述本文的研究动机, 并梳理国内外相关研究成果; 第三章和第四章是本文的核心内容, 详细叙述了本文提出的基于改进的 k -稀疏自编码器的恶意流量检测方法; 最后, 第五章对本文工作做了总结, 并立足现有成果, 对未来研究方向进行展望。以下对各章节内容做简要介绍:

第一章, 介绍本文研究的背景, 分析当前存在的问题, 引出本文方法, 然后深入剖析国内外研究现状, 最后概述本文的主要工作和论文组织结构。

第二章, 介绍本文研究涉及的相关技术及理论做全面介绍, 为后续文章奠定理论基础。

第三章, 提出特征的重要性和相关性评价系数, 改进隐含层选择策略的 k -稀疏自编码器, 并将其结合神经网络分类器联合优化, 通过隐含层的稀疏表达进行恶意流量检测。

第四章, 对于改进的 k -稀疏自编码器, 进行了一系列实验验证其得到的稀疏表达的提升效果。对联合优化框架, 进行与两阶段方法的对比实验, 验证联合优化带来提升。与对于整体的恶意流量检测方法, 完成充分的与其它恶意流量检测方法的对比实验以及分析。

第五章, 对全文工作进行总结, 分析不足之处并提出未来研究的方向。

2 相关理论与技术

2.1 恶意流量检测技术

2.1.1 基于特征表达的检测技术

利用特征表示来检测目标是当前常用的恶意流量检测技术，一般流程是首先从原始数据中提取特征，然后借助机器学习等方法进行恶意流量检测。这种方法的基础是构造充分的特征集合，构造特征集合的手段称为特征提取技术，即将原始数据映射到低维、高信息密度的特征空间。

在传统上，恶意流量特征提取主要依靠人工分析，该过程首先需要对恶意流量的生成进行深度剖析，包括明确恶意活动的具体类型，辨别蠕虫、木马所利用的漏洞及后门技术等，再分析对应特征的网络行为模式（表 2.1 给出了常见的恶意流量类别）。这种方式提取的特征较为准确但会消耗大量人力成本较大，且只能提取已知攻击的特征，面对零日攻击需要一个先发现再分析最后提取的反应时间，时效性较差。

表 2.1 恶意流量类别

序号	类别	概述
1	信息窃取	非法传输敏感数据的流量
2	远程控制	未经授权操控受害者主机的流量
3	拒绝服务	耗尽资源阻断服务访问的流量
4	勒索行为	受害主机上勒索软件发出的流量
5	信息探测	扫描目标获取攻击情报的流量
6	欺骗攻击	伪造身份欺骗用户的流量
7	主动感染	利用漏洞进行感染并传播的流量
8	信息篡改	非法修改数据破坏完整性的流量
9	恶意下载	强制安装恶意程序进行攻击的流量

如今，学术界针对恶意流量检测的研究重心已转向恶意流量特征自动提取^{[37][38][39]}，MooreZuev 2005 年的研究^[40]中，分析特征数据集并借助朴素贝叶斯模型构造分类器，得到 65% 的准确率，尽管效果并不优异，但他们给出的 248 个流量统计特征为后续基于流量特征的研究提供了指导意义。

在确定使用的特征并从原始流量中提取出后，会采用一些常见的机器学习和深度学习算法进行检测，具体的一些算法介绍如下：

(1) 朴素贝叶斯分类：是一种基于贝叶斯定理的统计推断方法，它计算特征与类别的条件概率，然后选择概率最大的类别作为未知样本的分类结果，其假设所有特征之间相互独立，但特征间实际上非条件独立，与其假设矛盾，导致分类效果不够优异。

(2) 随机森林：随机森林是多棵决策树的集成。以决策树为基本单元，通过集成大量的

决策树，就构成了随机森林，最后采取投票的方式，给出最终的分类结果，该方法是一种直观准确的方法。

(3)支持向量机：是一种有监督学习方法，其决策边界是对学习样本求解的最大边距超平面，进而完成分类，可以取得较好的检测效果。

(4)神经网络分类器：由大量的神经元相互连接组成，旨在处理复杂的非线性问题，具有强大的学习能力和适应性，流量特征在多层神经网络迭代计算，根据计算结果判断类别。

2.1.2 相关评估指标

为了评估和衡量流量检测系统在识别恶意行为方面的有效性和准确性，需要使用相关评估指标。评估指标有助于理解检测系统的强项和弱点，从而进行优化和对比。

根据流量真实属性，实际恶意流量定义为阳性（Positive），实际正常流量定义为阴性（Negative）。检测模型对网络流量的判定结果是一个二元分类，假设一个恶意流量检测系统，若触发恶意流量告警则记为 True，即预测阳性；若判定为正常流量则记为 False，即预测阴性。基于以上定义，可以得到如表 2.2 的二分类混淆矩阵。

表 2.2 混淆矩阵

预测结果\真实类别	Positive	Negative
True	TP（正确识别出恶意）	TN（正确识别出正常）
False	FP（错误识别为恶意）	FN（错误识别为正常）

准确率（Accuracy）是最常见的指标，关注的是全局预测效果，表示模型预测的所有正负样本中预测正确的比例，计算公式如式 2.1 所示。

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (2.1)$$

通常会直接使用准确率作为模型的评价指标，但在实际应用和样本分布不均的情况下，准确率可能会产生误导性结果。假设正样本占比为 1%，负样本占比为 99%，此时如果模型将所有样本预测为负样本，那么准确率可以达到 99%，但这种情况显然无法反映模型对正样本的真实识别能力，因此，单纯依赖准确率进行评估是不合理的，为了更好地评估模型，便有了下面这些评价指标。

精确率（Precision）关注正样本，指在预测为正例的样本中真正正例的占比，反应模型预估的精准程度，具体公式如式 2.2。

$$Precision = \frac{TP}{TP+FP} \quad (2.2)$$

召回率（Recall），又称真阳率，关注正样本，指数据集中的正样本被识别出来的比例，具体公式如式 2.3 所示。

$$Recall = \frac{TP}{TP+FN} \quad (2.3)$$

误报率（False Positive Rate），又称假阳率，指负样本中被预测为正样本的比例，具体

公式如式 2.4 所示。

$$FPR = \frac{FP}{TN+FP} \quad (2.4)$$

漏报率 (Miss Rate) 是正样本被预测为负样本占总正样本的比例, 计算公式如式 2.5 所示。

$$Miss Rate = \frac{FN}{TP+FN} \quad (2.5)$$

漏报率和召回率之间的关系可以描述为: $Miss Rate = 1 - Recall$, 因此, 召回率和漏报率是互补的, 当召回率增加时, 漏报率会减少。

F1 分数 (F1 Score) 是综合了精确率和召回率的一种指标, 特别适用于需要综合考虑误报和漏报的场景, 计算公式如式 2.6 所示。

$$F1 Score = \frac{2PR}{P+R} \in [0,1] \quad (2.6)$$

其中, P是精确率, R是召回率。F1 分数的取值范围从 0 到 1 的, 当数值达到 1 时, 意味着模型的预测结果达到了理想的最优状态, 而当数值为 0 时, 则表明模型输出效果处于最不理想的状态, 无法对数据进行有效预测。

2.2 自编码器技术

自编码器是一种简单的无监督神经网络模型, 包含输入层, 隐藏层和输出层, 可以分为编码过程和解码过程。编码时, 压缩并提取输入数据的特征表示; 解码时, 特征表示被用于重建输入数据。特征表示分为过完备表示和欠完备表示, 前者特征的维度高于输入维, 后者特征的低于输入维度。自编码器的编码、解码过程可以描述为式 2.6。

$$\begin{cases} z = f_{\theta}(x) = s(Wx + b) \\ y = g_{\theta}(z) = s(W'z + b') \end{cases} \quad (2.6)$$

其中, x 为输入数据, z 为特征表达, y 是重构数据, f_{θ} 是编码部分映射, g_{θ} 是解码部分映射。自编码器的目标是使最终的解码输出与输入误差最小, 对隐层输出添加约束防止 f_{θ} 和 g_{θ} 成为恒等映射, 自编码器的目标函具体如式 2.7 所示。

$$J(\theta) = \frac{1}{N} \sum_{i=1}^N L(x^{(i)}, z^{(i)}) + \lambda \cdot R(\theta) \quad (2.7)$$

其中, 使用 θ 代表自编码器中所有参数, $R(\theta)$ 为正则化项, 其作用是提升网络泛化能力, 避免过拟合。

稀疏自编码器是自编码器的一个变体, 其基本结构与自编码器类似, 不同之处在于, 稀疏自编码器在训练过程中加入了稀疏性约束, 以强制隐藏层的输出为稀疏表示。编码器输出稀疏表达, 解码器只能依靠少数几个特征重构数据, 这迫使自编码器在一遍遍训练中最终学习到最具判别性的少量特征, 减少冗余, 同时加快收敛。在赋予模型稀疏性时, 通采用两类方法, 一是利用KL散度引入稀疏性约束; 二是针对过完备自编码器, 利用 L_p ($p \in [0,1)$)伪范数或者 L_1 范数引入稀疏性。

本文的研究重点是 k -稀疏自编码器，相比于稀疏自编码器， k -稀疏自编码器在隐层表示的稀疏性上有更强的约束，它不仅仅是控制激活的平均强度，还要求在每个输入样本的隐层表示中只有 k 个神经元激活，其余神经元的激活值则置为零。 k -稀疏自编码器的特征选择过程大致可以描述为：编码器部分将输入数据映射到隐藏层，在隐藏层中找到其中最大的 k 个激活值，保持这些激活值不变并将其余的激活值设置为零。

按照 Andrew Ng 的研究^[10]，高维数据中的稀疏表达优于普通表达，因此在本文对流量数据进行特征选择时会考虑 k -稀疏自编码器。若隐含层的稀疏表达可以很好地重构输入数据，说明此稀疏表达成功学习关键特征，可较好地用于后续的训练任务。

2.3 本章小结

本章旨在对本研究中所涉及的各项技术进行全面概述，为后续讲解核心技术做理论铺垫。首先介绍了恶意流量检测这个领域的发展，对常用的特征和常见的模做了介绍，并分析了评价指标；然后，对自编码器模型的作用及原理进行介绍，并介绍它的变体：稀疏自编码器和 k -稀疏自编码。

3 技术路线

本文方法的基本思想是通过改进的 k -稀疏自编码器提取流量中区别比较明显的特征，建稀疏特征向量，练机器学习分类模型，利用该训练模型对其他流量进行检测，别其是否是恶意流量。方法整体流程如图 3.1 所示，包括流量预处理、特征提取以及模型训练与测试等部分。




图 3.1 基于改进的 k -稀疏自编码器恶意流量检测方法整体流程图

流量预处理部分主要完成对流量数据的清洗，括过滤重复的流量数据、对 service、state 等无序分类特征进行编码和对数值特征进行标准化处理，生成可用于模型训练输入的数据。

在特征提取部分，主要完成对流量数据的压缩和稀疏。本文对 k -稀疏自编码器的隐藏层进行了改进，首先通过评价系数算法计算得到特征重要性评价系数和特征相关性评价系数，以此为根据使用选择算法，提取出更能区分流量的特征信息，形成稀疏特征向量，用于后续的模型训练或检测。

而模型训练部分主要是利用特征提取阶段得到的稀疏表达构建恶意流量检测的模型。在此阶段，本文采用联合优化训练策略，即丢弃预训练后的 k -稀疏自编码器的解码器部分，并将编码器层用检测模型从原始数据空间到稀疏特征空间的非线性映射关系，在此架构基础上，通过端到端的联合训练机制，动态优化编码器参数与检测器参数，实现特征表示与分类决策的协同迭代更新，从而提升模型对恶意流量模式的鉴别能力。

下面分别对流量预处理部分、特征提取部分以及模型训练与检测部分做具体介绍。

3.1 流量预处理

本文使用公开流量数据集 UNSW_NB15 作为模型训练数据，该数据集有 47 个流量特征，其中包含 3 个无序分类特征和 44 个数值特征。分类特征无法直接作为模型的输入，数值特征需要消除量纲差异确保特征可比性，所以，在数据输入模型前对其进行预处理。流量预处理的流程如图 3.2 所示。



图 3.2 流量预处理流程

第一步，去除数据集中的重复数据。重复学习相同的样本可能会导致模型对某些特征过度依赖，误判这些特征的重要性而降低模型的泛化能力，所以去除重复数据防止模型过拟合，同时提高训练效率。

第二步，使用独热编码（One-Hot Encoding）对无序类别特征进行编码。无序类别特征是离散的、无序的，但分类模型通常认为特征是连续的、有序的，为了解决上述问题，采取独热编码。独热编码即一位有效编码，是使用 N 位状态寄存器来对 N 个状态进行编码，每个状态都有它独立的寄存器位，且在任意时候只有一位有效，即对于每一个有 m 个可能值的特征，经过独热编码后变成 m 个二元特征，并且这些特征互斥，每次只有一个激活。

第三步，对数值特征进行标准化，不同特征的量纲差异巨大（例如 `dur` 的范围大多是 0-1，`sload` 范围是 0-10 万），模型可能误认为数值大的特征更重要而弱化数值较低的特征的作用，所以消除量纲影响，使所有特征处于同一尺度，对模型检测性能的提升至关重要。本文采用 Z-score 标准化，核心原理是将每个特征独立映射到统一的统计尺度，具体来说，对每个特征列按照公式 3.1 单独计算。

$$z = \frac{x - \mu}{\sigma} \quad (3.1)$$

其中， x 是原始数据， μ 是数据的均值， σ 是数据的标准差。

3.2 特征提取

特征提取部分是本文方法的重点，其核心在于改进 k -稀疏自编码器。改进的 k -稀疏自编码器如图 3.3 所示，是一个由输入层、隐藏层（自注意力层）和输出层组成的神经网络。




图 3.3 改进的 k -稀疏自编码器

其中，输入层和输出层包含 n 个节点，隐藏层包含 i 个节点，标记为“+1”的圆圈为偏差单位，对应于截距项。在这个自编码器中， n 维输入数据首先被压缩到 i 维，然后，将 i 维的压缩数据作为特征评价系数算法的输入，计算得到重要性评价系数和联合相关性评价系数，再将这两个特征评价系数作为特征选择算法的输入，得到表示特征选择与否的矩阵掩码，最后，原将始压缩数据和矩阵掩码乘算，实现稀疏度为 k 的控制（空白的圆圈代表未被选中的特征）。

特征提取部分的主要工作就是通过改进的 k -稀疏自编码器对流量数据集进行特征提取，转换为稀疏表达，便于后续的检测。下面分别介绍特征评价系数的计算以及特征选择策略。

3.2.1 特征评价系数

本文根据香农信息熵理论定义了特征的重要性评价系数和联合相关性评价系数，并提出了两个系数的计算公式，下面分别对两个系数进行详细说明。

(1) 特征重要性评价系数

特征的重要性评价系数是量化通过某一特征识别出某类 C 的能力的指标，重要性评价系数越大，则该特征更具备区别类 C 与其他类的能力越强。

根据香农信息熵理论，若特征 f 在目标类 C 中呈现高度集中的概率分布，表明该特征对类 C 的代表性极强，若特征 f 在类 C_1 和 C_2 上的取值分布范围重叠较小，表示该特征在此两类上分布差异较大，具备优越的类间可分性，通过这个特征 f 能很好地区分类 C_1 和 C_2 。

基于以上理论，本文结合特征集中度和分布差异，提出了特征重要性评价系数，用于

量化一个特征对类别的表示能力和在类间的区分能力。特征集中度，即取值集中程度，是某一特征在一个类别内的取值分布集中程度的量化指标，一般来说，若特征在目标类中的取值越集中、离散程度越低，则该特征对该类别的表征能力就越强；分布差异是衡量同一特征在不同类别间取值分布差异程度的量化指标，一般来说，若特征在不同类别中的分布重叠区域越小，则该特征对类别间的区分能力就越强。

给定流量数据集 S ，包含 M 条数据，每条数据由 N 个特征值和一个类别标签构成，类别为正常或恶意两种，首先，可以定义特征集中度 P_{im} 为式 3.2。

$$P_{im} = \frac{1}{(Z_{\max} - Z_{\min})V_s} \quad (3.2)$$

表示特征 f_i 在 C_m 类上的分布集中度，其中， $Z_{\max}$ 、 $Z_{\min}$ 表示标准化后该特征的最大值和最小值， V_s 表示该特征取值的离散系数，计算公式为式 3.3。

$$V_s = \frac{\sigma}{\mu} \quad (3.3)$$

σ 是 f_i 特征值的标准差， μ 是 f_i 特征值的均值。 P_{im} 与 V_s 成反比，即离散系数越小（数据越集中），特征集中度越高。

然后，可以定义特征值分布差异 D_{imn} 为式 3.4。

$$D_{imn} = \frac{n_{im} \cdot n_{in}}{n_{imn}^2} \quad (3.4)$$

其中， n_{imn} 表示特征 f_i 在类别 C_m 和 C_n 的取值分布重叠区间内的样本总数， n_{im} 、 n_{in} 分别表示特征 f_i 在 C_m 类和 C_n 类的样本总数。当 $n_{imn} \rightarrow 0$ ，即 $D_{imn} \rightarrow \infty$ ，表示该特征值在两类无重叠，区分能力极强；当 $n_{imn} = n_{im} = n_{in}$ ，即完全重叠， $D_{imn} = 1$ ，该特征值在两类完全重合，无区分能力。

最后，结合 P_{im} 和 D_{imn} 可以定义特征重要性评价系数 I_i 为式 3.5。

$$I_i = P_{im} \cdot \frac{\sum_{k=1}^{L-1} D_{imk}}{L-1} \quad (3.5)$$

其中， L 表示总类别数，首先计算特征 f_i 在类别 C_m 中的类内集中度 P_{im} ，然后计算该特征在其它类别上的平均分布差异，最后乘算 P_{im} 和平均分布差异得到特征重要性评价系数 I_i 。本文对恶意流量的检测可以看作解决二分类问题，所以 $L = 2$ ， I_i 的计算公式可以简化为式 3.6。

$$I_i = P_{im} \cdot D_{imn} \quad (3.6)$$

特征重要性评价系数 I_i 越大，表明特征 f_i 在类别 C_m 中取值越集中（高 P_{im} ），且与另一个类别的分布差异越显著（高 D_{imn} ），即该特征对识别类别 C_m 越重要，在选择时权重越大。

（2）特征联合相关性评价系数

特征的联合相关性评价系数是量化特征 f 与剩余特征集合的相关性的指数，联合相关性评价系数越大，表明特征 f 与其余特征的信息重叠程度越高，特征联合相关性评价系数

的核心目的是评估特征 f 与数据集中其他所有特征之间的整体相关性，进而判断其是否冗余。

在信息论中，互信息是衡量两个变量之间相互依赖程度的指标，若两个变量 X 和 Y 完全独立，它们之间完全没有共享信息，则互信息 $I(X; Y) = 0$ ，若存在依赖关系，则互信息 $I(X; Y) > 0$ ，且两个特征共享的信息越多，互信息 $I(X; Y)$ 越大，相关性越强。

基于以上理论，本文采用标准化互信息来表示两两特征间的相关性，若特征 f 与剩余特征相关性较高，则表明该特征给特征集合带来了较大的冗余信息，特征选择时优先级需要降低。

设有原始流量特征集合 $F = \{f_1, f_2, f_3, \dots, f_N\}$ ，可以构造如式 3.7 所示的矩阵 H ，量化特征之间的联合相关性系数。

$$H = \begin{bmatrix} NMI_{11} & NMI_{12} & \dots & NMI_{1N} \\ NMI_{21} & NMI_{22} & \dots & NMI_{2N} \\ \vdots & \vdots & \ddots & \vdots \\ NMI_{N1} & NMI_{N2} & \dots & NMI_{NN} \end{bmatrix} \quad (3.7)$$

H 是 $N \times N$ 的方阵，矩阵元素是两个特征间的标准化互信息，其计算公式如式 3.8 所示。

$$NMI(f_i; f_j) = \frac{2 \times I(f_i; f_j)}{H(f_i) + H(f_j)} \quad (3.8)$$

其中， $I(f_i; f_j)$ 为特征 f_i 和特征 f_j 的互信息， $H(f_i)$ 和 $H(f_j)$ 分别为特征 f_i 和特征 f_j 的熵。根据式 3.9，

$$I(f_i; f_j) = H(f_i) + H(f_j) - H(f_i, f_j) \quad (3.9)$$

可知 $0 \leq NMI_{ij} \leq 1$ 。特征与自身完全相关，所以对角线元素为 1，且 $NMI_{ij} = NMI_{ji}$ ，所以 H 是一个对称矩阵。

特征联合相关系数矩阵为特征选择提供了冗余分析。在选择特征时，除了考虑其自身是否有价值，还应注意该特征与其它已经被选择的特征是否表示信息有较大重叠，如果该特征与其它已经被选择的特征的联合相关性系数较大，则视为可能引入冗余信息，意味着选择时该特征优先级要降低。特征联合相关系数矩阵有助于选择信息量大且相互独立的关键特征。

3.2.2 特征选择策略

计算各个特征的评价系数之后，要将这些系数运用到特征的选择中，自注意力机制可以结合特征评价系数进行特征选择，实现自编码器的隐藏层进行稀疏化处理，并且确保模型能够选择最重要的特征。

在隐藏层中计算每个特征的重要性评价系数和特征联合相关性矩阵，作为特征选择算法的输入，特征选择算法流程如图 3.4 所示。




图 3.4 特征选择流程图

首先，对于原始特征集合 $F=\{f_1, f_2, f_3, \dots, f_N\}$ ，选择特征值非零的特征，放入候选特征集合，其余特征放入非候选特征集合。在候选特征集合中，过滤重要性系数小于平均重要性系数 $I < \bar{I}$ 的特征到预移除特征集合 D ，剩余为预保留特征集合 R 。隐藏层的目标是实现 k 稀疏，若预保留特征集合中元素的数量大于 k ，则需要将其中的一些特征去除并补充到预移除特征集合，具体要补充的特征的数量 num_remove 可由式 3.10 得到，

$$num_remove = N - k - |D| \quad (3.10)$$

即总特征数量减去稀疏度再减去预移除特征集合的大小。对于非特征候选集，如果其中有重要性系数大于平均重要性系数 $\bar{I}$ 的特征，则将它们放到预添加特征集合中，并合并预移除特征集合和预添加特征集合为待评价特征集合。

然后，对于待评价特征集合中的每一个特征，计算它们的分数。分数的计算方法如式 3.11 所示。

$$score(f_i) = \frac{I_i}{\frac{1}{K} \sum_{k \in R} NMI(f_i, f_k)} \quad (3.11)$$

其中， I_i 是特征 f_i 的重要性评价系数， R 是预保留特征集合， K 是预保留特征的数量， $NMI(f_i, f_k)$ 是特征 f_i 和预保留特征的标准化互信息。例如，待评价特征集合 $V=\{f_1, f_3, \dots, f_i\}$ 时，遍历其中的所有的特征计算分数，首先计算特征 f_1 的分数，在联合相关性评价系数矩阵中找到特征 f_1 和预保留特征集合中所有特征对应的标准化互信息，计算它们的均值，作为分数计算的分子，分母是特征 f_1 的重要性评价系数，即特征的分数等于每个待评价特征的重要性系数与其与预保留特征联合相关性系数均值的比值。

最后，将所有待评价特征按分数降序排列，根据稀疏度 k 和预保留特征数量的差值，选出分数较高的那几个特征，和预保留特征一起组成最终保留特征集合。

3.3 模型训练

对于恶意流量的检测任务本质是一个二分类任务，所以本文创建一个用于二分类的分类神经网络模型用于稀疏表达的检测。为实现特征表示与下游分类任务的深度协同，本文提出了联合优化的训练方法，即将训练分为两个阶段，第一阶段为预训练阶段，第二阶段为联合优化阶段。在预训练阶段，通过重构任务的无监督学习训练改进的 k -稀疏自编码器，让编码器学习数据的低维稀疏表示；在联合优化阶段，将编码器的权重与分类神经网络的权重一起通过反向传播联合优化，此时，编码器和分类神经网络共享同一个目标函数，两者的参数在训练时被同时调整。

下面将详细地介绍本文训练方法的预训练阶段和联合优化阶段。

3.3.1 预训练

预训练是模型训练的第一阶段，主要工作是训练一个改进的 k -稀疏自编码器，学习输入数据的低维稀疏表示。自编码器通过重构输入数据，迫使隐藏层捕捉数据的本质结构，同时通过稀疏约束过滤冗余信息。

对改进的 k -稀疏自编码器的训练是无监督重构任务，目标函数为均方误差（Mean Squared Error, MSE），计算如式 3.11 所示。

$$E = ||x - \hat{x}||_2^2 \quad (3.11)$$

其中， $\hat{x} = f(Wz + b)$ ， $z = f(W'x + b')$ ，式中， W, b 为编码器权重与偏置， W', b' 为解码器参数， $f(\cdot)$ 为非线性激活函数。

传统的 k -稀疏自编码器选择线性函数激活值最大的 k 个来完成稀疏约束，本文用自注意力机制替代了这一选择机制。为了避免过早稀疏化导致特征信息丢失，会逐步引入自注意力机制。具体来说，在每次前向传播中，计算重构误差 E ，若 $E < \theta$ （预设阈值），判定当前稀疏特征 z 已具备足够表达能力，激活自注意力层，通过自注意力机制通过计算神经元的重要性评价系数和联合相关性评价系数，筛选一组重要神经元集合 Γ ，并对非重要神经元进行硬稀疏化，即其他神经元的激活值置为零 $z_{(\Gamma)^c} = 0$ 。

如果直接将编码器和神经网络分类模型结合到一起进行端到端训练，可能因随机初始化导致隐藏层激活冗余，预训练可以为联合优化提供鲁棒的初始参数，并加速联合优化的收敛，是联合优化的基础。

3.3.2 联合优化

在预训练阶段完成后，本文舍弃改进的 k -稀疏自编码器的解码器部分，仅保留编码器部分，并将其与二分类神经网络连接，具体架构如图 3.5 所示，原始数据 X 经过编码器的隐藏层后，得到的稀疏表达 Z ，该稀疏表达直接输入到二分类神经网络分类模型中完成分类。




图 3.5 检测器架构

在这一检测器结构中，编码器部分负责从原始数据中提取有效的特征表示，而分类网络则负责根据这些特征进行分类预测。二分类神经网络是一个三层的全连接神经网络，从编码器得到的特征表示直接作为其输入，输出为一个介于 0 和 1 之间的实数，表示输入数据属于恶意流量的概率。

整个网络（编码器+分类器）以端到端方式训练，而非独立优化各个模块。本阶段通过反向传播将编码器和分类器的参数优化过程结合在一起，使自编码器的特征学习与分类任务紧密联系，目标函数采用二元交叉熵损失（Binary Cross Entropy Loss），计算如式 3.12 所示。

$$\mathcal{L}_{cls} = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log (1 - \hat{y}_i)] \quad (3.12)$$

其中， y_i 为真实标签， $\hat{y}_i$ 为预测概率， N 为样本数量。

联合优化是预训练的延伸，是针对检测任务需求的精细化调整，通过舍弃解码器，避免重构任务对特征空间的过度约束，使稀疏表达更专注于分类判别特征的学习。最终，本阶段共同实现编码器权重矩阵的微调和分类神经网络参数的优化，得到输入为流量数据，输出为检测结果的恶意流量检测器。

3.4 检测

训练全部完成后，得到一个检测模型，该神经网络接受预处理后的流量数据作为输入，并输出恶意流量的概率。使用检测器进行检测的具体流程如图 3.6 所示。




图 3.6 检测器检测具体流程

输入检测器的流量数据通过神经网络进行前向传播，最终得到一个概率值。本文的目标是判定流量是否为恶意流量，所以需要对该概率值进一步处理，将其转换为流量类别。在本文使用的数据集中，正常流量标记为 0，恶意流量标记为 1，所以，本文设置一个阈值 0.5，当输出的概率值大于 0.5 时，判定为恶意流量，反之，判定为正常流量。

3.5 本章小结

本章的内容是本文研究重点。首先提出了神经元的评价系数和选择策略，并借助注意力机制改进了 k -稀疏自编码器的神经元选择过程，解决了传统 k -稀疏自编码器在面对网络流量时特征选择不合理的问题；接着介绍了本文采用的训练策略，先对改进的 k -稀疏自编码器进行预训练，再将编码器和用于检测的二分类神经网络结合到一起进行联合优化训练，基于此方法训练后，最终得到端到端的基于改进的 k -稀疏自编码器的恶意流量检测模型。

4 实验

本文设计进行三个实验，分别验证以下内容：（1） k -稀疏自编码器改进的有效性；（2）联合训练策略的效果；（3）与其他恶意流量检测方法的对比，评估其优越性。

4.1 实验环境

本文所有实验部署环境如下表 4.1 所示。

表 4.1 实验环境

操作系统	Windows 11 64-bit
处理器	AMD Ryzen 7 7840H
GPU	NVIDIA GeForce RTX 4060 Laptop GPU
编程语言	Python 3.9.20
深度学习框架	pytorch 2.5.1
依赖库	numpy 1.26.4
	pandas 2.2.3
	scikit-learn 1.6.1

4.2 实验结果和分析

4.2.1 实验数据集

实验使用公开数据集 UNSW_NB15，该数据集是恶意流量检测领域内一个非常著名且广泛使用的网络入侵检测数据集，由澳大利新南威尔士大学研究从实验室捕获的流量中生成，包含了正常流量和 9 种攻击类型的数据。2015 年由新南威尔士大学发布的公开的网络流量数据集 UNSW-NB15 的特征如表 4.2 所示。

表 4.2 UNSW-NB15 特征列表

序号	特征名称	序号	特征名称	序号	特征名称
1	总下行包数量	16	下行包平均间隔	31	总下行包长度
2	总上行包长度	17	下行包间隔总和	32	上行大包数量
3	总上行包数量	18	上行大包占比	33	下行包间隔标准差
4	下行包最大间隔	19	带 SYN 的包数	34	下行小包占比
5	上行与下行数据包数量比值	20	含 PSH 标志位的数据包数量	35	网络流持续时长
6	上行与下行数据传输量比值	21	数据包发送间隔时间平均值	36	每秒平均数据包传输数量
7	最小上行数据包字节长度	22	数据包发送间隔时间标准差	37	每秒平均数据传输字节数

8	上行包平均长度	23	上行包最大长度	38	每秒平均上行包数
9	上行包间隔总和	24	包发送最小间隔	39	下行包最大长度
10	上行包长度标准差	25	下行包平均长度	40	数据包最小长度
11	数据包最大长度	26	上行包最大时间	41	下行包最小长度
12	上行包最小间隔	27	上行包平均间隔	42	数据包长标准差
13	每秒平均下行包数	28	上行包间隔标准差	43	下行小包数量
14	下行包长度标准差	29	包发送最大间隔		
15	数据包平均长度	30	下行包最小间隔		

本文实验使用的 UNSW_NB15 训练集和测试集的详细信息如下表 4.3 所示。

表 4.3 UNSW_NB15 的训练集和测试集详细信息

	数据量	正常流量数据:恶意流量数据
训练集	175341	1:1
测试集	82332	7:3

4.2.2 验证 k -稀疏自编码器改进的有效性

本部分实验为验证改进 k -稀疏自编码器对二分类神经网络模型最终检测性能的影响。

本文方法的检测流程是首先使用自编码器从原始流量数据提取稀疏特征表达,然后再用稀疏特征表达作为二分类神经网络模型输入得到检测结果。因此,实验设计为,分别使用改进的 k -稀疏自编码器和传统的 k -稀疏自编码器提取到的稀疏表达作为二分类神经网络模型输入数据,比较模型输出结果。

改进的 k -稀疏自编码器模型、传统的 k -稀疏自编码器模型以及用于检测的二分类神经网络模型具体参数设置如表 4.3 所示,其中神经元个数括号中的数值分别代表当前网络的输入节点数和输出节点数。

表 4.3 实验模型参数设置

网络名称	结构组成	主要参数	输出尺寸
改进的 k -稀疏自编码器	输入层	神经元个数(196,10)	10
	隐藏层	神经元个数(10,10)	10
	输出层	神经元个数(10,196)	196
传统的 k -稀疏自编码器	输入层	神经元个数(196,10)	10
	隐藏层	神经元个数(10,10)	10
	输出层	神经元个数(10,196)	196
二分类神经网络模型	输入层	神经元个数(10,16)	16
	全连接层	神经元个数(16,8)	8
	输出层	神经元个数(8,1)	1

两个自编码器模型训练时的迭代次数是 100 次，batch_size 设置为 256，采用 Adam 优化器进行参数优化，稀疏度设置为 5，学习率设置为 1×10^{-4} 。sigmoid 模型训练时的迭代次数为 100 次，学习率设置为 1×10^{-3} ，同样采用 Adam 优化器进行参数优化。

在数据集 UNSW_NB15 上进行实验，得到 10 次实验的结果，计算比较各个指标的平均值，如图 4.1 所示。




图 4.1 验证改进有效性实验结果比较

从该图中可以看出，采用改进的 k -稀疏自编码器提取稀疏特征来训练检测模型，在整体性能上优于传统的 k -稀疏自编码器。使用改进的 k -稀疏自编码器得到的稀疏表达作为检测器输入时，检测器平均准确率为 87%，相较于使用传统的 k -稀疏自编码器提升了 29%；精确率为 84%，相较于使用传统的 k -稀疏自编码器提升了 11%；误报率为 12%，降低了 27%；F1 分数为 0.85，相比之下提升了 0.13；在召回率的表现上，使用改进的 k -稀疏自编码器的方法为 86%，而使用传统 k -稀疏自编码器的方法却为 96%，对应地，在漏报率上，使用改进后的 k -稀疏自编码器为 13.6%，高于使用传统 k -稀疏自编码器的 3.62%，这可能是因为使用改进的 k -稀疏自编码器的方法在判断时倾向于更加谨慎，提高了预测为正例的准确性（即精确率），则可能会漏掉一些真正的正例，导致召回率降低。总体上来说，实验结果证明了本文对 k -稀疏自编码器的改进是有效的，使用改进 k -稀疏自编码器得到的流量稀疏表达能训练出检测性能更佳的检测模型。

4.2.3 验证联合训练策略的有效性

本部分实验为验证两种不同的训练方法：分步训练和联合优化，对最终模型检测性能的影响。

分布训练是先训练改进的 k -稀疏自编码器，然后用自编码器提取稀疏表达，用这些稀疏表达训练二分类检测模型，联合优化是先预训练改进的 k -稀疏自编码器，再将自编码器的编码器部分的权重和二分类检测模型一起优化。本实验设计用分步训练和联合训练的方

法在公开数据集 UNSW_NB15 分别训练模型，比较它们的 10 次实验的平均结果，如图 4.3 所示。

改进的 k -稀疏自编码器和二分类检测模型参数依旧如表 4.3 所示。分步训练时，改进的 k -稀疏自编码器和二分类检测模型的迭代次数都是 100 次，batch_size 设置为 256，采用 Adam 优化器进行参数优化，改进的 k -稀疏自编码器的稀疏度设置为 5，学习率设置为 1×10^{-4} ，二分类检测模型学习率设置为 1×10^{-3} 。联合优化时，预训练迭代次数为 100 次，联合优化迭代次数为 100 次。




图 4.2 验证联合优化训练有效性实验结果比较

从该图中可以看出，采用联合优化的方法进行训练的模型整体上优于使用分步训练方法训练的。使用联合优化训练策略时，平均准确率为 90%，平均精确率为 90%，平均召回率为 87%，平均漏报率为 12.2%，平均误报率为 7%，平均 F1 分数为 0.88，相较于采用传统分步训练策略的，平均准确率、平均精确率和平均召回率分别提升了 3%、6%和 1%，平均漏报率和误报率分别降低了 1.4%和 5%，平均 F1 分数提升了 0.03。实验数据证明本文联合优化的训练方法对于检测效果是有提升的，提取得到的特征向量应该适配检测方法，联合优化的训练方法让编码器权重随着神经网络权重的迭代一起微调，使得编码器提取的稀疏表达更适应这个用于检测的二分类神经网络。

4.2.4 与现有方法对比

本部分实验为了验证本文方法的有效性，比较现有的恶意流量检测方法。标准多层感知器 MLP 是一种前馈神经网络，由多层神经组成，并且通过全连接层连接，经常用于分类任务，可作为对比方法；Zhang 等^[41]提出了一种改进的 LSTM 入侵检测算法模型，利用量子粒子群优化算来选择流量数据特征以降低特征维度，然后对降维后的网络流量进行检测，与本文提出模型检测流程类似，可做为有效对比方法。

所有涉及到的模型的训练和测试均在数据集 UNSW_NB15 上进行，各方法检测结果如

表 4.4 所示。

表 4.4 与现有方法对比实验结果

方法	准确率	误报率
本文方法	90.27%	7.6%
[41]	89.3%	1.84%
标准 MLP 模型	81.3%	21.15%

由表 4.4 可知，本文方法的各评价指标均优于标准 MLP 模型。在准确率上，本文方法最优，相较于文献[41]的模型和标准 MLP 模型分别提升了 0.97%和 8.97%，这主要归因于本文对 k -稀疏自编码器的改进和联合优化的训练策略；在误报率方面，本文方法显著优于标准 MLP 模型，相较下降低了 13.55%，但不如文献[41]的模型，其原因在于模型设计的侧重点差异，本文模型在保证低误报的同时，更注重整体性能的均衡性。

5 总结与展望

5.1 论文主要工作与贡献

本文针对数字化背景下，高维流量数据庞大、零日攻击越来越多的问题，提出了一种基于改进 k -稀疏自编码器的恶意流量检测方法。该方法主要从特征选择、模型训练和检测三个方面展开研究，旨在实现高效且准确的恶意流量检测。

首先，本文分析了 k -稀疏自编码器在流量数据的特征选择上的不足之处：特征的激活值比较集中，直接选择激活值最大的 k 个特征进行保留的方式过于简单粗糙。针对这一问题，本文提出了两个特征评价系数，以帮助 k -稀疏自编码器的隐藏层进行更加精准的特征选择。第一个是特征重要性评价系数，该系数量化了某一特征对于特定类型流量的代表性和区分性；第二个是联合相关性评价系数，该系数量化了特征之间的冗余度。将以上两个评价系数运用在隐藏层的数据稀疏中，能够更加合理地筛选出具有高区分度且冗余度较低的特征，从而提升特征选择的精确度。这样，改进的 k -稀疏自编码器能够更有效地捕捉到恶意流量的关键特征，进而提升检测性能。

其次，本文提出了一种先预训练再联合优化的训练策略。传统上，一般将自编码器和二分类神经网络模型分开训练，在检测时也将流量的稀疏表达从编码器输出后再输入二分类神经网络模型进行处理。然而，这种分开训练的方式可能导致两部分模型在参数更新时缺乏协同优化，从而影响整体性能。本文在预训练阶段首先训练改进的 k -稀疏自编码器，然后仅保留编码器部分接入二分类神经网络模型，在联合优化阶段，以统一的目标函数共同更新编码器和二分类神经网络模型的权重。该训练方式的主要优势在于，通过预训练阶段自编码器能够独立学习特征表示，而在联合优化阶段，编码器和二分类神经网络模型能够共享信息并协同优化，确保了特征表示和分类模型在训练过程中更好地配合，从而提升了整体模型的表达能力和检测精度。与传统的分开训练方法相比，这种联合优化方式不仅提高了模型的收敛速度，还能够避免特征学习和分类模型之间的潜在不匹配问题，从而实现更为高效的恶意流量检测。

最后，进行消融实验和对比实验。消融实验分为两组，比较去除 k -稀疏自编码器改进和保留改进的差异，和比较不进行联合优化训练和进行联合优化训练的差异，实验结果证明了 k -稀疏自编码器改进和联合优化训练策略的有效性。对比试验将本文方法得到的检测模型与标准 MLP 模型和 TSDL 模型进行对比，实验结果表明，本文模型在数据集 UNSW_NB15 上有更好的准确率，证明了本方法的有效性。

5.2 现存问题与今后工作

本文的检测模型在网络流量公开数据集上表现良好，但真实的网络环境和实验室生成的网络流量公开数据集仍然有差别，真实的网络流量通常包含多样化的应用，数据规模庞大且复杂，并且常常包含噪声。所以，将本文方法放到真实网络环境中去检测是重要的，

然而，本文未涉及这一方面的工作。

同时，本文最终的检测模型由两个部分结合而成，包含了较多的参数设置和优化过程，且模型在训练时必须按照先预训练再联合优化的顺序，训练模型的实际时间开销较大，如果未来使用更大的数据量进行训练，那应该考虑对模型训练的时间成本检测优化。

因此，本文今后将对方法进行改进，使训练阶段计算代价的降低，并将模型放入实际网络环境中检测。

参考文献

- [1] ITU. 2024 年事实和数字[EB/OL]. <https://www.itu.int/zh/mediacentre/Pages/PR-2024-11-27-facts-and-figures.aspx>, 2024-11-27.
- [2] 北京瑞星. 2024 年中国网络安全报告[EB/OL]. <https://www.rising.com.cn/2025/baogao/>, 2025-1-22.
- [3] Christodorescu M, Jha S, Seshia S A, et al. Semantics-aware malware detection[C]//Proceedings of the IEEE Symposium on Security and Privacy, 2005: 32-46.
- [4] Bruschi D, Martignoni L, Monga M. Detecting Self-mutating Malware Using Control-Flow Graph Matching[C]//Proceedings of the Detection of Intrusions and Malware & Vulnerability Assessment, 2006: 129 - 143.
- [5] Souri A, Hosseini R. A state-of-the-art survey of malware detection approaches using data mining techniques[J]. Human-centric Computing and Information Sciences, 2018, 8(1): 1-22.
- [6] Aslan Ö, Samet R. Investigation of possibilities to detect malware using existing tools[C]//Proceedings of the International Conference on Computer Systems and Applications (AICCSA), 2017: 1277-1284.
- [7] Yanfang Ye, Lingwei Chen, Shifu Hou, et al. DeepAM: a heterogeneous deep learning framework for intelligent malware detection[J]. Knowledge and Information Systems, 2018, 54(2): 265 - 285.
- [8] Naeem H, Cheng X, Ullah F, et al. A Deep convolutional neural network stacked ensemble for malware threat classification in internet of things[J]. Journal of Circuits, Systems and Computers, 2022, 31(17): 2250302.
- [9] Hinton G E, Salakhutdinov R R. Reducing the dimensionality of data with neural networks[J]. science, 2006, 313(5786): 504-507.
- [10] Ng A. Sparse autoencoder[J]. CS294A Lecture notes, 2011, 72(2011): 1-19.
- [11] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30: 5998-6008.
- [12] Xie J, Girshick R, Farhadi A. Unsupervised deep embedding for clustering analysis[C]//International conference on machine learning. PMLR, 2016: 478-487.
- [13] 贾翔龙. 工控协议逆向分析系统的研究与实现[D]. 北京: 北京邮电大学, 2019.
- [14] Gupta A, Gupta H P, Dutta T. A deep learning based traffic flow classification with just a few packets[C]//Proceedings of the IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS), 2021: 1-2.
- [15] 陈兴蜀, 陈敬涵, 邵国林, 等. 基于会话流聚合的隐蔽性通信行为检测方法[J]. 电子科技大学学报, 2019, 48(03): 388-396.
- [16] 唐璇, 严明, 万仕贤. 一种结合包检测与流检测的 SECS2 流量识别方法[J]. 计算机应用与软件, 2024, 41(09): 127-135.
- [17] 孙剑文, 张斌, 常禾雨. 网络异常检测中的流量表示研究[J]. 通信学报, 2025, 46(1): 192-209.

- [18] Ahmed M E, Ullah S, Kim H. Statistical application fingerprinting for DDoS attack mitigation[J]. IEEE Transactions on Information Forensics and Security, 2019, 14(6): 1471-1484.
- [19] Zolotukhin M, Hamalainen T, Kokkone T, et al. Increasing web service availability by detecting application-layer DDoS attacks in encrypted traffic[C]//Proceedings of the International Conference on Telecommunications (ICT), 2016: 1-6.
- [20] Garcia-Teodoro P, Diaz-Verdejo J, Maciá-Fernández G, et al. Anomaly-based network intrusion detection: Techniques, systems and challenges[J]. Computers & Security, 2009, 28(1-2): 18-28.
- [21] Wang T, Cai X, Nithyanand R, et al. Effective attacks and provable defenses for website fingerprinting[C]//Proceedings of the USENIX Conference on Security Symposium, 2014: 143-157.
- [22] 周成胜, 孟楠, 赵勋, 等. 基于深度学习的多会话协同攻击加密流量检测技术研究[J]. 信息安全研究, 2025, 11(01): 66-73.
- [23] Mongkollusamee S, Visoottiviseth V, Fukuda K. Combining communication patterns & traffic patterns to enhance mobile traffic identification performance[J]. Journal of Information Processing, 2016, 24(2): 247-254.
- [24] Shen M, Liu Y T, Zhu L H, et al. Fine-grained webpage fingerprinting using only packet length information of encrypted traffic[J]. IEEE Transactions on Information Forensics and Security, 2021, 16: 2046-2059.
- [25] Mamoto A H, Carvalho L F, Sampalo L D H, et al. Network anomaly detection system using genetic algorithm and fuzzy logic[J]. Expert Systems with Applications, 2018, 92: 390-402.
- [26] Maiti R R, Siby S, Sridharan R, et al. Link-layer device type classification on encrypted wireless traffic with COTS radios[C]//Proceedings of the European Symposium on Research in Computer Security, 2017: 247-264.
- [27] Fernandes G, Carvalho L F, Rodrigues J J P C, et al. Network anomaly detection using IP flows with principal component analysis and ant colony optimization[J]. Journal of Network and Computer Applications, 2016, 64: 1-11.
- [28] Garg S, Kaur K, Kumar N, et al. A hybrid deep learning-based model for anomaly detection in cloud datacenter networks[J]. IEEE Transactions on Network and Service Management, 2019, 16(3): 924-935.
- [29] Roosmalen J V, Vranken H, Eekelen M V. Applying deep learning on packet flows for botnet detection[C]//Proceedings of the ACM Symposium on Applied Computing, 2018: 1629-1636.
- [30] Marin G, Caasas P, Capdehourat G. DeepMAL-deep learning models for malware traffic detection and classification[C]//Proceedings of the International Data Science Conference-iDSC2020, 2021: 105-112.
- [31] 何慧, 张宏莉, 张伟哲, 等. 一种基于相似度的 DDoS 攻击检测方法[J]. 通信学报, 2004, (7): 176-184.
- [32] 陈锬奇, 王娟. 基于信息熵理论的教育网异常流量发现[J]. 计算机应用研究, 2010, (4): 1434-1436.
- [33] 张莹. 基于网络行为特征聚类分析的恶意代码检测技术研究[D]. 黑龙江: 哈尔滨工程大学, 2018.
- [34] Xu G Q, Guo B J, Su C H, et al. Am I eclipsed? A smart detector of eclipse attacks for Ethereum[J].

- Computers & Security, 2020, 88: 101604.
- [35] Lucia M J D, Maxwell P E, Bastian N D, et al. Machine learning raw network traffic detection[C]//Proceedings of the Artificial Intelligence and Machine Learning for Multi-Domain Operations Applications III, 2021, 11746: 185-194.
- [36] Radford B J, Apolonio L M, Trias A J, et al. Network traffic anomaly detection using recurrent neural networks[J]. arXiv Preprint, arXiv: 1803.10769, 2018.
- [37] Lee S, Kim S, Lee S, et al. LARGen: Automatic Signature Generation for Malwares Using Latent Dirichlet Allocation[J]. IEEE Transactions on Dependable and Secure Computing, 2016, 15(5): 771-783.
- [38] Zand A, Vigna G, Yan X, et al. Extracting Probable Command and Control Signatures for Detecting Botnets[C]//Proceedings of the ACM Symposium on Applied Computing, 2014: 1657-1662.
- [39] 鲁刚, 郭荣华, 周颖, 等. 恶意流量特征提取综述[J]. 信息安全, 2018, 18(9): 1-9.
- [40] Moore A W, Zuev D. Internet Traffic Classification Using Bayesian Analysis Techniques[C]//Proceedings of the ACM SIGMETRICS international conference on Measurement and modeling of computer systems, 2005: 50-60.
- [41] Zhang L, Yan H, Zhu Q. An improved LSTM network intrusion detection method[C]// Proceedings of the IEEE International conference on Computer and Communications, 2020: 1765-1769.

声 明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。据我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得四川大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

本学位论文成果是本人在四川大学读书期间在导师指导下取得的，论文成果归四川大学所有，特此声明。

作者签名： 吴欣蕊

导师签名： 何俊江

2025 年 5 月 10 日

学位论文使用授权书

本学位论文作者完全了解四川大学有关保留、使用学位论文的规定，同意学校保留并向国家有关部门或相关机构送交论文的原件、复印件和电子版，允许论文被查阅和借阅。本人授权四川大学将本学位论文的全部或部分内容编入有关数据库进行信息技术服务，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文，并用于学术活动。

（涉密学位论文在解密后适用于本授权书）

作者签名： 吴欣蕊

导师签名： 何俊江

2025 年 5 月 10 日

四川大学本科毕业论文 AI 工具使用声明

本人声明，在撰写题目为《基于改进稀疏自编码器的恶意流量检测方法》的本科毕业论文过程中，对 AI 工具的使用情况如下：

一、使用的 AI 工具及使用目的

序号	AI 工具	使用目的
1	deepseek	用于语言润色和资料检索辅助

二、使用程度说明

序号	章节	AI 工具	使用方式	处理方式
1	2.1.2	Deepseek	向 deepseek 提问某个概念的解释	重新组织语言解释概念
2	5	Deepseek	向 deepseek 提问写实验部分的框架	结合自身研究进行调整

在论文的 2.1.2 和 5 使用了上述 AI 工具。使用方式为 向 deepseek 提问某个概念的解释及实验部分的框架。在这些部分，AI 工具提供的内容占比约为 3%和 6%。

本人对 AI 工具提供的内容进行了重新组织语言解释概念和结合自身研究进行调整，以确保论文内容符合学术要求及本人的研究思路。

三、原创性与责任声明

本人确认，尽管使用了上述 AI 工具，但论文整体的研究思路、核心观点、论证过程及最终结论均为本人独立思考与研究的成果。论文中引用 AI 工具生成内容之处，均已按照学校规定的学术规范进行了明确标注。

若论文因 AI 工具使用不当或未按要求标注等原因出现学术不端问题，本人愿意承担全部责任。

学生签名： 吴欣蕊

指导老师签名： 何俊江

2025 年 5 月 10 日

致 谢

四年在四川大学的本科学习让我学到很多，我深知这一切离不开许多人给予的帮助与支持，在即将完本科阶段之际，感谢曾我本科求学生涯中给予帮助与支持的所有人。

首先，我要感谢给予我的悉心指导何老师。感谢您在毕设完成的整个过程中给予我的不懈支持，每次与您的讨论，都是我学术成长的宝贵经历。

其次，感谢我的同学和朋友们，在四年的学习生涯中，你们给予了我无尽的支持与帮助。无论是在学业上的互帮互助，还是在生活中的点滴关心，都让我感受到了爱与力量，我们一起度过了许多难忘的时光。

最后，感谢我的家人，感谢你们对我的支持和鼓励。无论我身处何地，你们始终是我不断前行的动力源，是我最坚强的后盾。